

Klasifikasi Penyakit *Chronic Kidney Disease* (CKD) Dengan Menggunakan Metode *Extreme Learning Machine* (ELM)

Ivan Fadilla¹, Putra Pandu Adikara², Rizal Setya Perdana³

Program Studi Teknik Informatika, Fakultas Ilmu Komputer, Universitas Brawijaya
Email: ¹ivanfadilla512@yahoo.com, ²adikara.putra@ub.ac.id, ³rizalespe@ub.ac.id

Abstrak

Ginjal merupakan organ penting yang berfungsi untuk menjaga komposisi darah dengan mencegah menumpuknya limbah dan mengendalikan keseimbangan cairan di dalam tubuh. *Chronic Kidney Disease* (CKD) merupakan salah satu penyakit pada ginjal yang disebabkan oleh infeksi pada ginjal dan juga penyumbatan yang disebabkan oleh batu ginjal. Dalam kasus ini tenaga medis maupun pakar masih belum maksimal di dalam mengklasifikasikan penyakit CKD, penulis menerapkan metode *Extreme Learning Machine* (ELM) pada persoalan klasifikasi penyakit CKD. ELM adalah salah satu metode klasifikasi jaringan saraf tiruan yang memiliki learning speed yang cepat dan berdasarkan penelitian sebelumnya memiliki nilai akurasi yang baik dibandingkan dengan metode yang ada dalam jaringan saraf tiruan. Pada penelitian ini didapatkan perbandingan data latih dan data uji yang optimal dengan rasio 70:30 dan jumlah hidden neuron sebanyak 50 hidden neuron menghasilkan nilai akurasi sebesar 96,7%. Dapat disimpulkan bahwa metode *Extreme Learning Machine* (ELM) cukup baik diimplementasikan untuk proses klasifikasi penyakit *Chronic Kidney Disease* (CKD).

Kata kunci: Ginjal, *Chronic Kidney Disease*, *Extreme Learning Machine*, Jaringan Syaraf Tiruan, Akurasi

Abstract

Kidneys are important organs that are focussed on maintaining blood composition by preventing accumulation of waste and controlling fluid balance in the body. Chronic Kidney Disease (CKD) is one of the diseases of the kidneys caused by infection in the kidney and also the blockage caused by kidney stones. In this case medical personnel and experts are still not maximized in classifying CKD disease, the authors apply the method of Extreme Learning Machine (ELM) on the problem of classification of CKD disease. ELM is one method of artificial neural network classification that has a fast learning speed and based on previous research has a good accuracy value compared with existing methods in artificial neural networks. In this research got comparison of data of train and optimal test data with ratio 70:30 and amount of hidden neuron counted 50 hidden neuron accuracy value equal to 96,7%. It can be concluded that the method of Extreme Learning Machine (ELM) is quite well implemented for the classification process of Chronic Kidney Disease (CKD) disease.

Keywords: Kidney, *Chronic Kidney Disease*, *Extreme Learning Machine*, Artificial Neural Network, Accuracy

1. PENDAHULUAN

Ginjal merupakan organ penting yang berfungsi menjaga komposisi darah dengan mencegah menumpuknya limbah dan mengendalikan keseimbangan cairan dalam tubuh, menjaga level elektrolit seperti *sodium*, *potassium* dan *fosfat* tetap stabil, serta memproduksi hormone enzim yang dapat membantu mengendalikan dalam tekanan darah memproduksi sel darah merah serta menjaga susunan tulang menjadi lebih kuat. Setiap hari

kedua ginjal menyaring sekitar 120-150 liter darah dan menghasilkan sekitar 1-2 liter urin. Ginjal tersusun atas unit penyaring yang dinamakan nefron. Nefron terdiri dari glomerulus dan tubulus. Glomerulus menyaring cairan dan limbah untuk dikeluarkan serta mencegah keluarnya sel darah dan molekul besar yang sebagian besar berupa protein. Selanjutnya melewati tubulus yang mengambil kembali mineral yang dibutuhkan tubuh dan membuang limbahnya. Ginjal juga menghasilkan enzim renin yang menjaga tekanan darah dan kadar garam serta hormon *erythropoietin*

Chronic Kidney Disease (CKD) adalah salah satu masalah kesehatan penduduk di seluruh dunia. Jumlah penyakit CKD ini bertambah seiring pesatnya laju pertumbuhan penduduk. Menurut hasil *Global Burden of Disease* pada tahun 2010, penyakit CKD mendapat peringkat ke 27 di tahun 1990 dan peringkatnya naik menjadi peringkat ke 18 di tahun 2010. Di Indonesia sendiri penyakit ginjal adalah penyakit no 2 dengan pembiayaan terbesar setelah penyakit jantung berdasarkan BPJS kesehatan. Menurut data hasil Riset Kesehatan Dasar (Riskesdas) pada tahun 2013, populasi umur ≥ 15 tahun yang terdiagnosis CKD sebesar 0,2%. Angka ini lebih rendah dibandingkan prevalensi CKD di Negara Negara lain, juga hasil penelitian Perhimpunan Nefrologi Indonesia (Pernefri) tahun 2006, yang mendapatkan prevalensi CKD sebesar 12,5%. Hal ini karena Riskesdas 2013 hanya menangkap data orang yang terdiagnosis CKD sedangkan sebagian besar CKD di Indonesia baru terdiagnosis pada tahap lanjut dan akhir (Kementerian Kesehatan RI, 2017).

Adapun orang yang beresiko mengalami gagal ginjal kronis ini seperti orang yang memiliki tekanan darah tinggi, menderita diabetes, memiliki keluarga pengidap gagal ginjal kronis. Penyebab gagal ginjal kronis disebabkan oleh infeksi pada ginjal, gangguan ginjal polistik dan juga penyumbatan yang disebabkan oleh batu ginjal atau gangguan prostat. Dikarenakan gejala penyakit CKD ini hampir sama seperti penyakit pada umumnya, terkadang orang salah menafsirkan penyakit CKD karena pengetahuan tentang penyakit ini yang kurang dan juga mendiagnosis penyakit ini tanpa didasari fakta dan pertimbangan medis lainnya.

Klasifikasi merupakan pengelompokan yang didasarkan pada data-data yang ada. Terdapat banyak metode yang digunakan untuk mengklasifikasikan sebuah data seperti *Learning Vector Quantization* (LVQ) dan *Extreme Learning Machine* (ELM). Salah satu penelitian yang terkait dengan klasifikasi adalah penelitian yang dilakukan oleh Pangaribuan (2016). Pada penelitian tersebut mengangkat metode *Extreme Learning Machine* (ELM) yang diterapkan pada penyakit diabetes mellitus yang dibandingkan oleh metode *backpropagation* dimana didapatkan hasil *Mean Square Error* (MSE) yang lebih baik dari metode *backpropagation* sebesar 0,4036 dan tingkat kesalahan MSE yang mendekati 0 adalah hasil yang baik namun pada penelitian ini tidak dijelaskan bagaimana

mendapatkan parameter yang optimal untuk mengklasifikasikan penyakit diabetes mellitus dalam penerapannya menggunakan metode ELM. Selain itu, pada penelitian lain yang menggunakan data penyakit yang sejenis yaitu penyakit CKD dengan menggunakan metode C4.5 yang di dalam penelitian tersebut didapatkan hasil akurasi 91,50% (Rianto, 2015). Akan tetapi pada penelitian yang diangkat oleh Huang, Zhu dan Siew (2006) didapatkan hasil perbandingan metode ELM dengan beberapa metode lain seperti SVM, RBF, C4.5 dan di dapatkan hasil dimana metode ELM memiliki nilai testing rate sebesar 77.57% dimana nilai ini merupakan testing rate yang paling besar dibandingkan dengan metode-metode lainnya.

Extreme Learning Machine (ELM) adalah metode jaringan syaraf tiruan yang diangkat oleh Huang yang dimana merupakan *single hidden layer feedforward neural network* yang dimana dipercaya dapat mengatasi kekurangan paa metode jaringan syaraf tiruan terutama dalam hal *learning speed.*, ELM memiliki fitur yang menarik dan signifikan. Atribut-atribut penyakit CKD dapat dijadikan pedoman atau acuan dalam membantu mengklasifikasikan penyakit. Sehingga *Extreme Learning Machine* (ELM) diharapkan mampu memberikan hasil yang optimal terhadap Klasifikasi Penyakit *Chronic Kidney Disease* (CKD). Berdasarkan latar belakang diatas, telah dijelaskan bahwa metode ELM merupakan metode yang telah terbukti memberikan hasil yang baik berdasarkan testing rate dibandingkan dengan metode-metode lainnya. Harapannya implementasi metode ELM dapat membantu mengklasifikasikan penyakit CKD dengan tepat dan akurat yang akan berguna bagi tenaga medis maupun pakar di dalam mengklasifikasikan penyakit CKD ini.

2. LANDASAN KEPUSTAKAAN

2.1. Kajian Pustaka

Penelitian pertama yang dilakukan oleh Humaini (2015) tentang penerapan metode *Extreme Learning Machine* (ELM) untuk memprediksi kondisi cuaca di wilayah malang. Penelitian tersebut bertujuan untuk mendapatkan arsitektur yang optimal dengan memperhatikan beberapa atribut seperti tekanan udara, suhu, angin dan kelembapan udara yang dapat memprediksi cuaca di wilayah malang. Di dapatkan kesimpulan pada penelitian ini bahwa metode *Extreme Learning Machine* (ELM) dapat

menghasilkan nilai akurasi *testing* sebesar 80% memenuhi kriteria data yang ada.

Penelitian kedua dilakukan oleh Pangaribuan (2016) yang menerapkan metode *Extreme learning Machine* (ELM) terhadap penyakit diabetes mellitus. Penelitian tersebut bertujuan untuk membuat sistem peramalan baru yang dapat menjadi alat bantu dalam penentuan apakah seseorang menderita diabetes mellitus atau tidak. Hasil dari penelitian membandingkan antara metode *Extreme Learning Machine* (ELM) dengan metode *backpropagation* menghasilkan nilai MSE pada ELM sebesar 0,4036 dan nilai MSE pada *backpropagation* sebesar 0,9425.

Penelitian ketiga dilakukan oleh Sari (2017) yang menerapkan metode *Extreme Learning Machine* (ELM) untuk peramalan data *time series*. Penelitian tersebut bertujuan untuk memprediksi harga penutupan harian saham BRI yang diperdagangkan pada bursa efek Jakarta. Hasil dari penelitian terlihat bahwa metode ELM memiliki rata rata waktu belajar lebih cepat, dengan kata lain ELM lebih akurat dan cepat dalam proses pembelajaran dengan nilai 0,38309 detik dan nilai RMSE sebesar 21,58585.

Penelitian keempat dilakukan oleh Rahma, Wijaya, dan Prawito (2016) menggunakan metode ELM sebagai alat bantu klasifikasi Stroke Iskemik Akut dan Normal dan di dapatkan bahwa hasil akurasi pelatihan ELM berdasarkan nilai fitur BSI adalah diatas 98% dan hasil akurasi pengujian ELM diatas 85%. Dengan ini metode ELM memiliki akurasi yang tinggi dan waktu pelatihan yang lebih cepat.

Penelitian kelima dilakukan oleh Rianto dan Satvika (2017) menggunakan algoritme C4.5 dalam mendeteksi Penyakit Ginjal Kronis dan di dapatkan hasil proses pengujian yang dilakukan dengan menggunakan *cross-validation* dan berdasarkan hasil yang telah dihitung aplikasi ini memiliki akurasi 91,50% pada saat *decision tree* dibuat tanpa menggunakan *preprocess* menu.

Penelitian keenam dilakukan oleh Santosa, Widjanarko, dan Supriyanto (2016) menggunakan RBF dalam memodelkan prediksi penyakit ginjal kronik. Didapatkan hasil pengujian yang memiliki akurasi 93,75% pada parameter Learning Rate 0,2 dan Epoch sebesar 2000 lebih baik dibandingkan dengan penelitian sebelumnya dengan menggunakan metode BP yang menghasilkan akurasi sebesar 91,71%.

Penelitian yang terakhir dilakukan oleh Huang, Zhu, dan Siew (2006) menjelaskan tentang metode *Extreme Learning Machine*

(ELM) dan terdapat hasil perbandingan metode ELM dengan beberapa metode lainnya seperti SVM, SAOCIF, Cascade-Correlation, AdaBoost, C4.5, RBF dan Heterogeneous RBF. Penerapan perbandingannya dilakukan dalam aplikasi diagnosis penyakit diabetes. Didapatkan hasil metode ELM mendapatkan nilai *Testing Rate* sebesar 77,57% yang dimana metode ELM ini memiliki *Testing Rate* yang paling besar dibandingkan dengan metode-metode lainnya.

2.2. Chronic Kidney Disease (CKD)

Chronic Kidney Disease (CKD) merupakan salah satu penyakit yang menyerang organ ginjal dimana keadaan organ ginjal menurun secara progresif, kronik, maupun menetap dan berlangsung. Kriteria yang terdapat pada penyakit ginjal kronik ini adalah timbulnya kerusakan ginjal lebih dari 3 bulan dengan kata lain terjadinya kelainan *structural* maupun *fungsional* (Faradilla, 2009). Adapun tanda dan gejala penyakit *Chronic Kidney Disease* (CKD) antara lain terjadinya kelainan pada urin terdapat dalam protein, sel darah putih/*lekosit*, darah/*eritrosit*, bakteri, *creatin* darah naik, *hemoglobin* turun, *protein* yang selalu positif (Wariant, 2011). Penyakit CKD ini dapat menyerang siapapun dari mulai balita hingga usia lanjut. Seiring pertumbuhannya penduduk juga salah satu faktor timbulnya penyakit CKD ini.

2.3. Jaringan Syaraf Tiruan

Komputer digital mengguguli di dalam perhitungan numeric dan manipulasi simbol yang terkait dibandingkan manusia. Jaringan saraf tiruan merupakan sistem komputasi parallel yang besar dan yang terdiri dari beberapa prosesor sederhana dengan banyak interkoneksi yang mencoba model untuk menggunakan beberapa prinsip “organisasi” yang diyakini digunakan oleh manusia (Jain dan Mao, 1996). Penelitian jaringan saraf tiruan telah mengalami tiga periode dalam eksistensi aktifitas. Pada sekitar tahun 1940 oleh McCulloch dan Pitts menjadi yang pertama dalam penelitian ini, kedua terjadi pada sekitar tahun 1960 dengan teori konvergensi *perceptron* karya Minsky dan Papert’s dapat mengurangi keterbatasan dari *simple perceptron*. Penelitian yang dilakukan ini membuat dampak berkurangnya antusias orang di dalam ilmu komputer dan membuat jeda penelitian tentang jaringan saraf tiruan berlangsung hampir 20

tahun sejak sekitar tahun 1980. Jaringan saraf tiruan mendapatkan banyak minat baru. Perkembangan dibalik kebangkitan ini adalah Hopfield pada tahun 1982 tentang pembelajaran algoritme propagasi balik untuk *perceptrons multilayer* (*multilayer feedforward network*) yang diajukan pertama kali oleh Werbos dan kemudian di populerkan oleh Rumelhart pada tahun 1986, Anderson dan Rosenfeld memberikan sejarah yang rinci pada perkembangan jaringan saraf tiruan (Jain dan Mao, 1996).

Funahashi dan Hornik beserta para peneliti lainnya telah menunjukkan bahwa jaringan saraf dengan kompleksitas yang memadai dapat mendekati fungsi apapun serta fungsi tidak dapat diketahui sampai tingkat akurasi yang diinginkan dengan hanya satu lapisan tersembunyi oleh karena itu, model JST dapat di representasikan yang terdiri dari lapisan input, lapisan tersembunyi dan juga lapisan *output* yang saling terhubung 1 sama lainnya (Mingyue, Cheng, dan Yu, 2016).

2.4. Extreme Learning Machine (ELM)

Extreme Learning Machine adalah metode jaringan syaraf tiruan yang dipercaya mampu mengatasi kelemahan metode jaringan syaraf tiruan lainnya terutama dalam hal *learning speed* dimana ELM memiliki satu *hidden layer* yang sering disebut dengan istilah *single hidden layer fastforward neural network* (Huang, Zhu, dan Siew, 2006). Algoritme ELM tidak melakukan pelatihan pada bobot *input*. Tetapi pada ELM bobot akan diinput secara acak dan juga terdapat nilai bias yang dapat membantu memaksimalkan nilai yang di dapatkan pada proses ELM. Sehingga algoritme ELM dapat dipercaya memiliki nilai *learning speed* yang optimal dan cepat yang mampu menghasilkan generalisasi yang baik.

2.4.1 Algoritme ELM

Huang, Zhu, dan Siew (2006) menjelaskan bahwa proses ELM memiliki tiga tahapan, yaitu masukan data *training*, fungsi aktivasi, dan banyaknya jumlah *hidden neuron* maka langkah-langkah training pada metode ELM yang akan diproses adalah sebagai berikut:

Langkah 1 : Inisialisasi semua bobot dan jumlah di dengan bilangan acak kecil [0,1]. Dengan ukuran bobot W adalah [Hidden Neuron

x Input Layer].

Langkah 2 : Hitung matrix inisialisasi *output hidden layer*

$$H_{init} = (x_{11} \cdot w_{11}^T) + bias \quad (1)$$

Keterangan:

x_{ij} = data pada baris ke I kolom ke j

w_{ij}^T = nilai bobot transpose pada baris ke i kolom ke j

Bias = nilai bias dengan nilai range [0,1]

Langkah 3 : Setelah menghitung nilai H_{init} mencari nilai matrix H

$$H = 1/(1 + EXP(-H_{init})) \quad (2)$$

Langkah 4 : Menghitung matrix H^+ setelah mencari nilai matrix H

$$H^+ = (H^T H)^{-1} H^T \quad (3)$$

Kemudian mencari bobot ke *output layer* (β)

$$\beta = H^T t_i \quad (4)$$

Keterangan :

H^T = nilai H Transpose.

t_i = target dari proses training.

Langkah 5 : Menghitung nilai Y prediksi yang akan di bandingkan dengan nilai target.

$$\hat{Y} = H \cdot \beta \quad (5)$$

Langkah 6 : Mencari nilai max dari nilai Y prediksi yang di dapatkan, serta membandingkan nilai max dengan dengan nilai Y prediksi untuk dapat mengetahui hasil kelas nya.

Langkah 7 : Menghitung semua perubahan

bobot dan jumlah hidden neuron yang optimal.

Langkah 8 : Simpan nilai β dari bobot dan jumlah *hidden neuron* yang optimal

Setelah didapatkan proses *training* dilakukan proses *testing* yang dimana dengan tahapan sebagai berikut:


Langkah 1 : Mengambil nilai bobot, bias, *hidden neuron*, dan fungsi aktivasi yang digunakan dalam proses *training*.

Langkah 2 : Menghitung nilai keluaran *hidden neuron* dengan persamaan 1.

Langkah 3 : Menghitung nilai keluaran *hidden neuron* dengan fungsi aktivasi yang digunakan pada proses *training*.

Langkah 4 : Menghitung nilai Y prediksi yang akan dibandingkan dengan nilai target dengan menggunakan nilai bobot keluaran yang digunakan pada proses *training* dengan menggunakan persamaan 5.

2.4.2 Arsitektur *Extreme Learning Machine* (ELM)



Gambar 1. Arsitektur *Extreme Learning Machine* (ELM)

2.5. Normalisasi Data

Dalam Melakukan proses perhitungan dalam klasifikasi penyakit *chronic kidney disease* (CKD), perlu dilakukan sebuah proses normalisasi yang dimana proses ini merubah seluruh data dengan jarak tertentu yang sehingga seluruh data memiliki nilai jarak yang sama (patro et al, 2015). Proses normalisasi yang digunakan pada penelitian ini adalah mentransformasikan pada nilai jarak yang lebih kecil [0,1] dengan menggunakan metode *min max normalization* yang memiliki persamaan:

$$x' = \frac{(x-a)}{((b-a)+(1-0))} \quad (6)$$

Keterangan:

x' = Data yang sudah di transformasi

x = Data Awal

a = Data minimum dari keseluruhan data

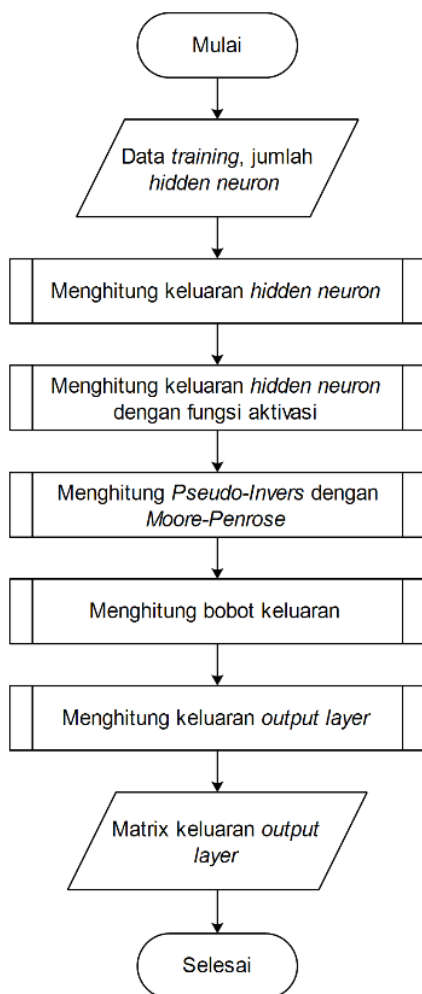
b = Data maksimum dari keseluruhan data

3. PERANCANGAN

Pada perancangan sistem terdapat cara kerja sistem secara keseluruhan dalam menggunakan metode *Extreme Learning Machine* (ELM) dari mulai proses normalisasi seluruh data yang akan digunakan hingga mendapatkan hasil klasifikasi. Pada proses ini terlebih dahulu sistem akan menerima masukan berupa data training dan jumlah *hidden neuron*. setelah menerima masukkan data akan di normalisasi dan di proses untuk mencari nilai keluaran *hidden neuron* setelah menemukan nilai *hidden neuron* proses selanjutnya akan mencari nilai keluaran *hidden neuron* dengan fungsi aktivasi. Terdapat beberapa fungsi aktivasi yang akan diuji disini. Setelah mendapatkan nilai keluaran *hidden neuron* dengan fungsi aktivasi selanjutnya mencari nilai *pseudo-invers* dengan *moore-penrose*. Selanjutnya proses ELM akan dilanjutkan dengan mencari nilai bobot keluaran yang akan digunakan untuk menghitung keluaran *output layer*. Gambar 2 menunjukkan diagram alir untuk pelatihan pada proses menggunakan metode

3.1. Data yang digunakan

Data yang digunakan dalam penelitian adalah berdasarkan data riwayat penyakit *Chronic Kidney Disease* (CKD) yang terdiri atas 2 Alternatif pilihan kelas yang digunakan, yakni kelas CKD dan Not CKD yang terdiri atas 24 parameter nilai yang merujuk terhadap penyakit CKD. Setiap parameter nilai memiliki nilai pembobotan yang berbeda beda. Berikut adalah 24 parameter yang digunakan di dalam pada klasifikasi penyakit CKD. Tabel 1 menunjukkan penjelasan tentang parameter data.



Gambar 2. Diagram Alir Proses ELM

Tabel 1 Parameter Data


No	Kode	Parameter	Nilai
1	age	Age	Dalam Tahun
2	bp	Blood pressure	Dalam mm/Hg
3	sg	Specific gravity	(1.005,1.010,1.015,1.020,1.025)
4	al	Albumin	(0,1,2,3,4,5)
5	su	Sugar	(0,1,2,3,4,5)
6	rbc	Red blood cells	Normal / Abnormal
7	pc	Pus cell	Normal / Abnormal
8	pcc	Pus cell clumps	Present / NotPresent

9	ba	Bacteria	Present / NotPresent
10	bgr	Blood glucose random	Dalam mgs/dl
11	bu	Blood urea	Dalam mgs/dl
12	sc	Serum creatinine	Dalam mgs/dl
13	sod	Sodium	Dalam mEq/L
14	pot	Potassium	Dalam mEq/L
15	hemo	Hemoglobin	Dalam gms
16	pcv	Packed cell volume	Dalam %
17	wc	White blood cell count	Dalam cells/cumm
18	rc	Red blood cell count	Dalam millions/cmm
19	htn	Hypertension	Yes / No
20	dm	Diabetes mellitus	Yes / No
21	cad	Coronary artery disease	Yes / No
22	appet	Appetite	Good / Poor
23	pe	Pedal edema	Yes / No
24	ane	Anemia	Yes / No

4. HASIL DAN PEMBAHASAN

Pada penelitian ini dilakukan klasifikasi penyakit *chronic kidney disease* (CKD) dengan *Extreme Learning Machine* (ELM) dan dilakukan beberapa pengujian untuk menguji beberapa aspek terhadap sistem yang dibuat pada penelitian ini. Hasil akhir dari pengujian ini adalah mendapatkan rasio data latih dan data uji yang optimal, mendapatkan jumlah hidden neuron yang optimal, mendapatkan fungsi aktivasi yang baik di dalam menggunakan data penyakit CKD dengan menggunakan *Extreme Learning Machine* (ELM) dan juga mendapatkan nilai *precision*, *recall*, *fi-measure*,

dan juga Akurasi yang terbaik dengan menggunakan parameter – parameter pengujian yang optimal..




Gambar 3. Grafik Hasil Pengujian Rasio Jumlah Data Latih dan Data Uji

Berdasarkan grafik hasil pengujian pada Gambar 3 perubahan nilai rasio jumlah data latih dan data uji hanya berpengaruh sedikit pada perubahan nilai akurasi. Hasil akurasi yang didapatkan cenderung tidak stabil dan rata-rata rasio yang memiliki nilai akurasi paling besar di dapatkan pada rasio 70:30 dengan banyaknya jumlah data latih berjumlah 197 data dan data uji sejumlah 84 data. Rasio 70:30 memiliki akurasi sebesar 98,4%.




Gambar 4. Grafik Hasil Pengujian Jumlah Hidden Neuron terhadap Akurasi

Berdasarkan grafik hasil pengujian pada Gambar 4 rata rata yang memiliki nilai akurasi tertinggi sebesar 98,7 % adalah dengan jumlah hidden neuron sebanyak 50 hidden neuron. Pada grafik dapat dilihat juga semakin banyak jumlah hidden neuron tidak semakin baik nilai akurasi yang didapatkan karena semakin banyak hidden neuron semakin banyak proses yang dilakukan sehingga proses pada ELM menjadi tidak optimal. Pada jurnal Dong Xiao juga dikatakan bahwa jumlah hidden neuron yang paling baik di dapatkan dalam range 20-60.



Gambar 5. Grafik Hasil Pengujian Pengaruh Fungsi Aktivasi terhadap nilai akurasi

Berdasarkan grafik hasil pengujian pada Gambar 5 rata rata yang memiliki akurasi paling baik dengan menggunakan nilai fungsi aktivasi sigmoid biner dengan nilai akurasi sebesar 98,7 % lebih tinggi dibandingkan dengan fungsi aktivasi lainnya. Hal ini membuktikan bahwa untuk data *chronic kidney disease* (CKD) menggunakan metode *Extreme Learning Machine* (ELM) nilai aktivasi yang paling cocok adalah fungsi aktivasi sigmoid biner dikarenakan data yang digunakan bernilai biner.



Gambar 6. Grafik Hasil Pengujian Pengaruh Keseimbangan Data Set

Berdasarkan grafik hasil pengujian pada Gambar 6 didapatkan hasil pengujian dengan pada data A nilai *Precision*, *Recall*, *F1-measures* dan Akurasi rata rata memiliki nilai yang lebih tinggi dibandingkan dengan data B ini membuktikan bahwa pada data B dikarenakan jumlah NotCKD yang cenderung sedikit membuat pada pelatihan kurang dapat mengenali saat data tidak seimbang, dengan data A yang memiliki nilai *precision* 96,7%, *recall* 96,8%, *f1-measure* 96,6% dan akurasi 96,7%. Artinya, keseimbangan data mempengaruhi secara signifikan dalam penerapan metode *Extreme Learning Machine* (ELM).

5. KESIMPULAN DAN SARAN

5.1. Kesimpulan

Berikut adalah kesimpulan yang dapat diambil dari hasil yang telah didapatkan dari perancangan, implementasi dan pengujian yang telah dilakukan yaitu:

1. Metode *Extreme Learning Machine* (ELM) adalah salah satu metode jaringan syaraf tiruan yang dapat digunakan untuk mengklasifikasikan data pada setiap kelasnya. Pada hasil yang di dapatkan pada penelitian ini metode ELM dapat mengatasi keterbatasan tenaga medis dalam mendeteksi dan mendiagnosa penyakit *Chronic Kidney Disease* (CKD)
2. Proses awal yang harus dilakukan dalam mengimplementasikan metode *Extreme Learning Machine* (ELM) adalah menentukan bobot acak sejumlah dengan banyaknya hidden neuron dikalikan dengan 24 parameter data yang digunakan. Dilakukan proses dengan bobot acak yang telah ditentukan sampai menemukan Y Prediksi. Pada proses data uji bobot yang digunakan adalah bobot yang telah dipakai di data latih. Dengan jumlah *hidden neuron* sebanyak data latih, proses selanjutnya sama seperti proses data latih tetapi untuk mencari nilai Y Prediksi digunakan variable beta yang terdapat pada data latih.
3. Klasifikasi pada penyakit *Chronic Kidney Disease* (CKD) dengan menggunakan metode *Extreme Learning Machine* (ELM) dapat di implementasikan dengan baik dan didapatkan hasil yang paling optimal dengan jumlah perbandingan data latih dan data uji sejumlah 70:30 dengan jumlah *hidden neuron* optimal sebanyak 50 *Hidden Neuron* didapatkan nilai rata – rata *precision* 96,7%, *recall* 96,8%, *f1-score* 96,6%, dan Akurasi 96,7%

5.2. Saran

Berikut merupakan saran yang dapat digunakan untuk penelitian selanjutnya yaitu:

1. Penambahan variasi besar jumlah *hidden neuron* di dalam pengujian untuk lebih memperdalam analisis dari nilai klasifikasi yang diproses dengan menggunakan metode *Extreme Learning Machine* (ELM)

2. Penggunaan varian dari algoritma *Extreme Learning Machine* (ELM) serta menggunakan optimasi yang dapat dilakukan pada *Extreme Learning Machine* (ELM).

6. DAFTAR PUSTAKA

- Faradilla, N., 2009. “Gagal Ginjal Kronik (GGK)”. Fakultas Kedokteran Universitas Riau.
- Fikriya, Z., Irawa, I., Soetrisno., 2017. “Implementasi Extreme Learning Machine untuk Pengenalan Objek Citra Digital”. Jurnal Sains dan Seni ITS, Volume 6, No.1.
- Huang, G., Zhu, Q., Siew, C.K., 2006. ”Extreme Learning Machine : Theory and Applications”. Journal Neurocomputing, 70(1): 489 – 501.
- Humaini, Q., 2015. “Jaringan Saraf Tiruan Extreme Learning Machine (ELM) untuk Memprediksi Kondisi Cuaca di Wilayah Malang”. Universitas Islam Negeri Maulana Malik Ibrahim, Malang.
- Jain, K., Mao, J., 1996. “Artifical Neural Networks: A Tutorial”.
- Kementerian Kesehatan RI, 2017. “Infodatin Pusat Data Informasi Kementerian Kesehatan RI”.
- Kohavi, R., Provost, F., 1998. “Glossary of Terms Special Issue on Application Of Machine Learning and the Knowledge Discovery Process”. Kluwer Academic Boston.
- Mingyue, Q., Cheng, Li., Yu, So., 2016. “Application of the Artifical Neural Network in predicting the direction of stock market index”. Fukoka Institute of Technology.
- Pangaribuan, J., 2016. ”Mendiagnosis Penyakit Diabetes Melitus dengan Menggunakan metode Extreme Learning Machine”. Jurnal ISD, Volume 2. No.2.
- Patro, K., Sahu, K., 2015. “Normalization: A Preprocessing Stage”. Department of CSE & IT.
- Rahma, O., Wijaya, S., Prawito., 2016. “Implementasi Extreme Learning Machine

- Sebagai Alat Bantu Klasifikasi Stroke Iskemik Akut dan Normal dengan Metode Brain Symmetru Index”. Program Studi Teknologi Biomedis Program Pascasarjana Universitas Indonesia.
- Rianto, R., Satvika, N., 2017. “Rancang Bangun Aplikasi Pendeteksi Penyakit Ginjal Kronis dengan Menggunakan Algoritme C4.5”. Fakultas Teknik dan Informatika, Universitas Multimedia Nusantara, Tangerang.
- Rubini, J., 2015. “UCI Machine Learning Repository Data Set”.
- Santosa, S., Widjanarko, A., Supriyanto, C., 2016. “Model Prediksi Penyakit Ginjal Kronik Menggunakan Radial Basis Function”. Politeknik Negeri Semarang, Pascasarjana Teknik Informatika Universitas Dian Nuswantoro Semarang.
- Sari, V., 2017. “Aplikasi Extreme Learning Machine untuk Peramalan Data Time Series (Studi Kasus : Saham Bank BRI)”. Akademi Statistika Muhamadiyah, Semarang.
- Xiao, D., Li, B., Mao, Y., 2017. “A Multiple Hidden Layer Extreme Learning Machine Method and Its Application”. Information Science and Engineering School, Northeastern University, Shenyang 11004, China.